

Universo e entrada na rede de creches

Auditoria das bases locais, definição do alvo, primeira estimação e validação fora da amostra em 2024 e 2025.

837.179 linhas de opções	296.084 crianças-ano únicas	98,7% cobertura geográfica
------------------------------------	---------------------------------------	--------------------------------------

Limite de uso

A documentação local afirma que os registros foram anonimizados e que os indicadores gerados não representam a realidade. Assim, os números desta nota validam o pipeline e a estratégia de previsão; não são estimativas oficiais de demanda para alocação de recursos.

Data de corte: 30 de agosto de 2026

Arquivos originais preservados; novos artefatos gravados apenas em Pedro/Modelo.

Decisões que ficam congeladas nesta versão

Decisão	Versão 0.1	Por quê
Alvo	criança única × ano × território × grupamento	A chave de inscrição superestima o total em 15,95%; opções e registros repetidos não são novas crianças.
Território inicial	bairro de residência	É a menor unidade comum entre inscrições e nascimentos disponível na pasta.
Evento	inscrição inicial, qualquer situação final	Confirmação, cancelamento e fila ocorrem depois e dependem de capacidade/classificação.
Universo	coortes de nascimentos por bairro/ano	Fluxo administrativo anual observado; é superior a interpolar idade em pequena área quando o dado não existe.
Estimador	PPML com offset, indicadores territoriais ridge e tendência por grupamento	O alvo é contagem e a exposição varia muito entre bairros.
Validação	origem expansiva 2024 e 2025	Replica a informação disponível na data de cada previsão; sem embaralhar anos.

Conclusão executiva
A previsão técnica para 2026 é 66,801 inscrições no universo anonimizado, contra 59,718 no cenário de persistência. O intervalo condicional de 95% do PPML-NB é [64,159; 69,443]. A discrepância entre cenários é material e deve permanecer visível para decisão.

O modelo ainda não contém renda, emprego ou CadÚnico, porque nenhuma dessas bases com granularidade residencial local e frequência anual está presente no diretório. Inserir proxies municipais ou do local de trabalho produziria falsa precisão.

O que existe na pasta e o que cada base mede

Base local	Período / grão	Cobertura observada	Uso na Frente 1
Query A — inscrições	2021–2025; uma opção de creche por linha	837.179 linhas; 343.308 chaves de inscrição; 296.084 crianças-ano	Numerador após deduplicação por aluno_anon e ano.
Queries B/C — questionário	2021–2025; resposta por pergunta/inscrição	4.357.119 respostas; 97,62% das inscrições; 13 perguntas/ano	Perfil condicional dos inscritos; não identifica a propensão da população.
NascidosvivosRJ.xlsx	2016–2026; bairro × ano	168 códigos, dos quais 2 residuais; 2026 está parcial	Exposição por coorte. Para prever 2026 usam-se apenas 2022–2025.
Microáreas SME	233 geometrias; estoque	232 códigos; duplicidade 7.28; 1 geometria inválida	Dimensão futura. Não há microárea de residência nas inscrições.
Oferta pública/parceira	2021–2025; unidade/grupamento; layouts variáveis	~1.547–1.560 linhas públicas/ano e 218–353 linhas parceiras/ano	Covariada futura, com data de corte; não é denominador da demanda.
Unidades unificadas	unidade; localização	1.941 linhas principais + 1.914 parceiras; 871/872 unidades da Query A vinculadas	Localização da unidade: essencial à Frente 2, insuficiente para residência da Frente 1.

Achado de qualidade

A malha contém duas geometrias com código 7.28 e uma geometria inválida. Antes de qualquer spatial join, é preciso definir se as duas partes devem ser dissolvidas e reparar a geometria de modo documentado.

Fontes locais auditadas: README_dicionario_dados.md; README.txt da pasta OferecimentosEvagas; SME_Processo_Inscricao_Creche_parametrizações.docx; arquivos CSV, XLSX e shapefile do repositório.

Construção do alvo: contar crianças, não linhas

A Query A tem três camadas de multiplicidade: várias opções por inscrição, mais de uma inscrição da mesma criança no mesmo processo e reaparecimento da criança em anos distintos. A unidade estatística correta para a entrada anual na rede é (ano, aluno_anon). O endereço e o grupamento da primeira ocorrência cronológica resolvem conflitos raros; os conflitos serão mantidos em log de qualidade.

Ano	chaves de inscrição	crianças únicas	excesso se não deduplicar
2021	73.283	57.690	27,03%
2022	64.055	57.820	10,78%
2023	51.331	45.918	11,79%
2024	82.690	71.757	15,24%
2025	71.949	62.899	14,39%
Total	343.308	296.084	15,95%

Definição operacional

$A(m,g,t)$ = número de valores distintos de aluno_anon no ano t, com residência harmonizada no território m e grupamento g, independentemente da situação posterior da opção.

- Não somar filas por creche: a mesma criança aparece em várias opções.
- Não condicionar a Confirmado ou Lista de espera: isso mistura demanda inicial com oferta, prioridade e decisão administrativa.
- Não usar endereço da creche para territorializar a criança: isso pertence à escolha condicional da Frente 2.

Cobertura

Após harmonizar apenas variantes inequívocas de bairro, 98.73% das crianças-ano entram no painel. Localidades ambíguas não foram imputadas à força.

Primeira inscrição versus reinscrição observada

Ano	primeira observada	reinscrição observada	% reinscrição
2021	57.690	0	0.0%
2022	50.546	7.274	12.6%
2023	44.514	1.404	3.1%
2024	62.441	9.316	13.0%
2025	44.733	18.166	28.9%

Uma reinscrição observada é a aparição da mesma hash aluno_anon em ano posterior. Em 2021, todas as crianças são classificadas como primeira observação por censura à esquerda; portanto, esse rótulo não equivale a “primeira inscrição da vida”. O salto para 18.166 reinscrições em 2025 pode refletir política, fila acumulada, mudança de cobertura ou mecanismo de geração da base — precisa de confirmação operacional.

Modelo modular recomendado

$$A(m,g,t) = A_nova(m,g,t) + A_retorno(m,g,t)$$

- A_nova: universo de crianças elegíveis que nunca havia aparecido antes do corte observado.
- A_retorno: estoque elegível de inscritos não atendidos e/ou candidatos que precisam renovar a manifestação de interesse.
- Para produção, solicitar à SME a distinção nativa entre inscrição inicial, transferência, renovação automática e permanência em fila.

Não usar o questionário como controle de entrada
As respostas socioeconômicas são observadas somente depois que a família já se inscreveu. Elas descrevem quem entrou no cadastro, mas não permitem comparar inscritos e não inscritos; usá-las diretamente na equação de propensão cria seleção por construção.

Universo potencial e a taxa de entrada

O arquivo de nascidos vivos é uma exportação do SINASC por bairro de residência e ano. A fonte administrativa é apropriada para seguir coortes; a SMS informa que o SINASC foi implantado no Rio em 1993 e o TABNET oferece consultas de nascimentos desde 2006 [10].

Grupamento	Proxy de coorte na versão 0.1	Justificativa nos registros
Berçário	$\text{Nasc}(m,t-1) + \text{Nasc}(m,t-2)$	Concentra crianças de até dois anos no ano letivo.
Maternal I	$\text{Nasc}(m,t-3)$	Coorte modal compatível com idade observada.
Maternal II	$\text{Nasc}(m,t-4)$	Coorte modal compatível com idade observada.

$$p(m,g,t) = E[A(m,g,t) \mid \text{informação disponível antes da inscrição}] / E(m,g,t)$$

Essa taxa é uma propensão operacional de manifestação de demanda, não uma probabilidade causal. Na base anonimizada, ela pode inclusive exceder limites substantivos porque o README informa que os indicadores não preservam a realidade. Por isso o estimador trabalha a contagem com offset e o PDF evita interpretar p como porcentagem real.

Limitações do denominador atual

- Ano, e não mês: o corte exato de 6 meses a 3 anos e 11 meses não pode ser aplicado ao universo.
- Bairro, e não microárea: não há alocação direta dos nascimentos aos 232 códigos territoriais.
- Mudanças de bairro: novos códigos têm séries históricas nulas e exigem ponte territorial estável.
- Migração entre nascimento e inscrição não é observada.

Próxima base prioritária

Solicitar SINASC com mês de nascimento e residência geocodificada ou já agregada por microárea, sob governança adequada. Esse pedido melhora mais o denominador do que adicionar muitas covariadas de baixa granularidade.

Primeiro modelo estimado

Para cada bairro m , grupamento g e ano t , a versão 0.1 estima:

$$A(m,g,t) \sim \text{Poisson}(\mu(m,g,t))$$
$$\log \mu(m,g,t) = \log E(m,g,t) + \alpha(m) + \gamma(g) + \delta(g) \cdot (t-2021)$$

$\alpha(m)$ são indicadores de bairro, $\gamma(g)$ diferenças médias entre grupamentos e $\delta(g)$ tendências específicas. Os indicadores são estabilizados com ridge ($\alpha = 10^{-4}$) porque há até 166 bairros, três grupamentos e somente três a cinco anos no treino. O PPML é coerente com uma média condicional multiplicativa de contagem e tem fundamentos para painéis com heterogeneidade multiplicativa [4]. Modelar diretamente uma fração seria alternativa quando o denominador real estiver validado [5].


Componente	Incluído agora?	Regra temporal
Coorte elegível	Sim, como offset	Conhecida antes do ano previsto.
Efeito territorial	Sim, bairro	Somente histórico do treino.
Tendência por grupamento	Sim	Extrapolável para ano futuro.
Efeito fixo de ano	Não no forecast	Um dummy de 2025 não existe ao prever 2025; seria inestimável fora da amostra.
Demanda defasada	Benchmark, não regressora	Painel curto gera risco de viés dinâmico [9].
Renda/emprego/CadÚnico	Não	Ausentes em granularidade residencial compatível.
Oferta/capacidade	Não nesta versão	Precisa estar congelada antes da inscrição e ligada ao território de residência.

A literatura econômica torna renda, emprego materno, preço/acesso e estrutura familiar candidatos substantivos [1–3]. Porém, acesso à creche também altera emprego e renda; no experimento do Rio, acesso gratuito afetou resultados laborais maternos [1]. Logo, covariadas contemporâneas podem ter causalidade reversa. Para previsão, usar valores defasados e tratar coeficientes como preditivos, não causais.

Validação fora da amostra: 2024 e 2025

A avaliação segue origem expansiva: treina 2021–2023 e prevê 2024; depois treina 2021–2024 e prevê 2025. Esse desenho preserva a ordem temporal e explicita atualização/reestimação, como recomendado na literatura de testes OOS [7].

Teste	Modelo	Obs.	Prev.	WAPE	Viés	MAE	Cob. 95%
2024	PPML-FE	70.828	42.653	41.0%	-39.8%	59.5	43.9%
2024	Persistência	70.828	43.286	39.8%	-38.9%	57.8	—
2025	PPML-FE	61.902	65.114	24.0%	+5.2%	30.4	86.3%
2025	Persistência	61.902	66.673	16.0%	+7.7%	20.2	—



Leitura: 2024 é uma quebra estrutural/operacional, não um erro pequeno de calibração. O PPML subestima o total em 39,8% e a persistência em 38,9%. Em 2025, o PPML reduz o viés agregado para +5,2%, mas a persistência tem WAPE menor (16,0% contra 24,0%). Os intervalos condicionais também subcobrem, sobretudo em 2024; seguindo Gneiting e Raftery [8], cobertura e largura precisam ser avaliadas conjuntamente, e não apenas o ponto médio.

Primeira estimativa para 2026

Grupamento	universo proxy	PPML-FE	persistência	intervalo PPML 95%
Bercario	116.068	29.987	26.081	[28.031; 31.943]
Maternal I	62.526	24.430	21.531	[22.849; 26.010]
Maternal II	64.371	12.384	12.106	[11.574; 13.194]
Total	242.965	66.801	59.718	[64.159; 69.443]

Número de referência
PPML-FE: 66,801. Persistência: 59,718. Diferença: 7,083 crianças na base anonimizada.

O intervalo exibido usa uma distribuição binomial negativa com dispersão estimada nos resíduos ($\alpha \approx 0,0529$), condicionada aos parâmetros e ao universo proxy. Ele não incorpora integralmente erro no SINASC, incerteza de geocodificação, mudança de política ou erro de estimação dos efeitos territoriais. Portanto, é um intervalo mínimo, não uma banda de risco de política pública.

Por que não escolher automaticamente o PPML

- Há apenas dois anos OOS; um deles contém quebra severa.
- O challenger de persistência venceu o PPML em WAPE nos dois testes.
- A previsão pontual deve ser reportada como faixa de cenários até que 2024 seja explicado e os dados reais substituam os anonimizados.

Recomendação de auditoria: manter ambos os cenários no painel decisório; promover um modelo a campeão somente após reprocessar dados reais, fixar o corte anual e repetir backtests em mais anos ou origens mensais.

Renda, emprego e vulnerabilidade: o que é utilizável

Fonte	Frequência	Granularidade pública	Veredito para a Frente 1
RAIS / Novo Caged	anual / mensal	microdados não identificados; geografia pública não garante residência em microárea	Não usar como emprego residencial local sem validar campo e série; local do estabelecimento mede outra coisa [14].
CadÚnico aberto	amostra anual; agregados municipais mensais	público chega tipicamente ao município; acesso identificado exige autorização	Insuficiente para microárea pública. Solicitar agregado anual/mensal por residência à gestão municipal [15].
Questionário da inscrição	anual	resposta individual dos inscritos	Não estima a probabilidade de entrar; pode caracterizar composição e classificação.
Data Lake municipal	depende da tabela	BigQuery com permissões por projeto	Infraestrutura confirmada, mas o catálogo público não comprova tabelas específicas de CadÚnico/SME. É necessário acesso e inventário de schema [13].
Habite-se / novas moradias	não presente	não verificada nesta pasta	Candidata, desde que geocodificada e congelada antes do ano previsto.

Pedido mínimo ao Data Lake / SME

- Snapshot anual da inscrição inicial, hash estável da criança, data do evento, grupamento e microárea de residência.
- CadÚnico agregado por microárea e ano-mês: crianças elegíveis, renda per capita, monoparentais, responsável feminino ocupado e benefícios; sem identificadores.
- Estoque anterior: matriculados, não atendidos e renovações por microárea/grupamento, todos no mesmo corte.
- Oferta conhecida antes da inscrição: capacidade pública/parceira, turno, abertura e fechamento.

Critério de admissibilidade

Uma variável só entra no forecast se tiver: residência local compatível; atualização ao menos anual; histórico 2021–2025; data de disponibilidade anterior ao alvo; dicionário estável; e plano explícito para revisões.

Riscos, testes de robustez e próxima iteração

Risco	Evidência atual	Teste / correção
Quebra em 2024	inscritos sobem de 45.918 para 71.757; unidades na Query A de 496 para 844	Separar mudança de cobertura, inclusão de parceiras e mudança de processo; reconstruir universo comparável.
Geografia	bairro informado; 1,1% dos registros múltiplos têm CEP conflitante	Usar residência na data da primeira inscrição; crosswalk CEP→microárea versionado; auditoria de fronteiras.
Denominador	nascimentos anuais, sem mês	Obter mês/microárea; comparar com projeção etária e matrículas passadas.
Painel curto	cinco anos e muitos efeitos	Shrinkage hierárquico; comparar pooling, ridge e intercepto aleatório [6].
Dinâmica	reinscrições crescem fortemente em 2025	Modelar fluxos separadamente; evitar FE dinâmico ingênuo devido ao viés de painel curto [9].
Intervalos	cobertura 95% de 43,9% em 2024 e 86,3% em 2025	Bootstrap por território + cenários de corte/política; avaliar interval score [8].

Sequência recomendada

- 1. Explicar e documentar a quebra de 2024; sem isso, nenhum modelo de tendência é auditável.
- 2. Substituir a base anonimizada pelo extrato real agregado, com a mesma lógica de deduplicação.
- 3. Congelar a ponte bairro/microárea e a regra mensal de elegibilidade por grupamento.
- 4. Estimar A_nova e A_retorno separadamente; depois somar distribuições, não só médias.
- 5. Acrescentar covariadas uma a uma, exigindo ganho OOS contra persistência.
- 6. Publicar ficha do modelo: corte, versão das bases, cobertura, métricas e falhas conhecidas.

Contrato com a Frente 2

A Frente 1 termina na quantidade prevista de inscrições por origem territorial e grupamento. A Frente 2 distribui essa massa entre unidades elegíveis. Nenhuma característica da unidade deve ser necessária para estimar o universo; e a Frente 2 deve validar escolha condicionando ao total efetivamente inscrito.

$$D_{\hat{i},g,t} = \sum_m A_{\hat{m},g,t} \times P_{\hat{i} \mid \text{inscrição},m,g,t}$$

Campo	Frente 1	Frente 2	Regra
ano	obrigatório	obrigatório	Ano letivo/processo, não ano de criação bruto.
cod_territorio	bairro na v0.1; microárea alvo	origem da criança	Uma tabela de ponte versionada.
grupamento	Bercario, Maternal I, Maternal II	mesmo domínio	Sem renomear silenciosamente.
codigo_unidade	não aparece no output granular	obrigatório	Entra somente na probabilidade condicional.
a_hat	média prevista	insumo	Nunca arredondar antes da soma.
incerteza	quantis/distribuição	combinar com P_hat	Evitar somar limites célula a célula como se fossem independentes.

Schema proposto para entrega

ano | cod_territorio | tipo_territorio | grupamento | e_hat | a_hat | p10 | p50 | p90 | modelo | data_corte | versao

Auditoria antes da integração

A soma de P_hat sobre unidades elegíveis deve ser 1 para cada (m,g,t). A Frente 1 deve reconciliar a soma de A_hat com seus totais publicados. O produto só é liberado quando ambas as identidades passarem.

Reprodutibilidade e referências

Artefato	Função
f1_est.py	Leitura, deduplicação, painel, PPML, OOS, projeção e exportação.
results/f1_panel.csv	Painel bairro × grupamento × ano construído sem sobrescrever originais.
results/f1_oos_pred.csv	Previsões célula a célula nos dois testes.
results/f1_oos.csv / .tex	Tabela de métricas.
results/f1_prev_2026.csv	Primeira projeção territorial completa.
results/f1_resumo_2026.csv / .tex	Resumo por grupamento e total.
figures/f1_oos.png	Figura usada nesta nota.

Referências acadêmicas

- [1] Barros, R. P.; Olinto, P.; Lunde, T.; Carvalho, M. (2013). The impact of access to free childcare on women's labor market outcomes: evidence from a randomized trial in low-income neighborhoods of Rio de Janeiro. World Bank. [fonte](#)
- [2] Heckman, J. J. (1974). Effects of Child-Care Programs on Women's Work Effort. Journal of Political Economy, 82(2). [fonte](#)
- [3] Blau, D. M.; Robins, P. K. (1988). Child-Care Costs and Family Labor Supply. Review of Economics and Statistics, 70(3), 374–381. [fonte](#)
- [4] Wooldridge, J. M. (1999). Distribution-free estimation of some nonlinear panel data models. Journal of Econometrics, 90(1), 77–97. [fonte](#)
- [5] Papke, L. E.; Wooldridge, J. M. (1996). Econometric methods for fractional response variables. Journal of Applied Econometrics, 11(6), 619–632. [fonte](#)
- [6] Rao, J. N. K.; Molina, I. (2015). Small Area Estimation, 2nd ed. Wiley. [fonte](#)
- [7] Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. International Journal of Forecasting, 16(4), 437–450. [fonte](#)
- [8] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. JASA, 102(477), 359–378. [fonte](#)
- [9] Nickell, S. (1981). Biases in Dynamic Models with Fixed Effects. Econometrica, 49(6), 1417–1426. [fonte](#)

Fontes oficiais e documentação

- [10] SMS Rio — SINASC e TABNET municipal. [fonte](#)
- [11] SME Rio — Matrícula 2024: calendário, elegibilidade e processo classificatório. [fonte](#)
- [12] SME Rio — Transparência Creches: fila, matrículas e capacidade com atualização prevista mensal. [fonte](#)
- [13] IplanRio — Data Lake Municipal e acesso via BigQuery. [fonte](#)
- [14] MTE — Microdados RAIS e CAGED. [fonte](#)
- [15] MDS — dados e acesso ao Cadastro Único. [fonte](#)