

Universo e entrada na rede de creches

Auditoria das bases locais, definição do alvo, primeira estimação e validação fora da amostra em 2025.

837.179 linhas de opções	296.084 crianças-ano únicas	98,7% cobertura geográfica
------------------------------------	---------------------------------------	--------------------------------------

Limite de uso

A documentação local afirma que os registros foram anonimizados e que os indicadores gerados não representam a realidade. Assim, os números desta nota validam o pipeline e a estratégia de previsão; não são estimativas oficiais de demanda para alocação de recursos.

Data de corte: 30 de agosto de 2026

Arquivos originais preservados; novos artefatos gravados apenas em Pedro/Modelo.

Decisões que ficam congeladas nesta versão

Decisão	Versão 0.1	Por quê
Alvo	criança única × ano × território × grupamento	A chave de inscrição superestima o total em 15,95%; opções e registros repetidos não são novas crianças.
Território inicial	bairro de residência	É a menor unidade comum entre inscrições e nascimentos disponível na pasta.
Evento	inscrição inicial, qualquer situação final	Confirmação, cancelamento e fila ocorrem depois e dependem de capacidade/classificação.
Universo	coortes de nascimentos por bairro/ano	Fluxo administrativo anual observado; é superior a interpolar idade em pequena área quando o dado não existe.
Estimador	PPML com offset, indicadores territoriais ridge e tendência por grupamento	O alvo é contagem e a exposição varia muito entre bairros.
Validação	treina 2021–2024 e prevê 2025	2024 fica no histórico de treino, mas não entra nas métricas OOS devido à quebra de cobertura.

Conclusão executiva
A previsão técnica para 2026 é 66,801 inscrições no universo anonimizado, contra 59,718 no cenário de persistência. O intervalo condicional de 95% do PPML-NB é [64,159; 69,443]. A discrepância entre cenários é material e deve permanecer visível para decisão.

O modelo ainda não contém renda, emprego ou CadÚnico, porque nenhuma dessas bases com granularidade residencial local e frequência anual está presente no diretório. Inserir proxies municipais ou do local de trabalho produziria falsa precisão.

O que existe na pasta e o que cada base mede

Base local	Período / grão	Cobertura observada	Uso na Frente 1
Query A — inscrições	2021–2025; uma opção de creche por linha	837.179 linhas; 343.308 chaves de inscrição; 296.084 crianças-ano	Numerador após deduplicação por aluno_anon e ano.
Queries B/C — questionário	2021–2025; resposta por pergunta/inscrição	4.357.119 respostas; 97,62% das inscrições; 13 perguntas/ano	Perfil condicional dos inscritos; não identifica a propensão da população.
NascidosvivosRJ.xlsx	2016–2026; bairro × ano	168 códigos, dos quais 2 residuais; 2026 está parcial	Exposição por coorte. Para prever 2026 usam-se apenas 2022–2025.
Microáreas SME	233 geometrias; estoque	232 códigos; duplicidade 7.28; 1 geometria inválida	Dimensão futura. Não há microárea de residência nas inscrições.
Oferta pública/parceira	2021–2025; unidade/grupamento; layouts variáveis	~1.547–1.560 linhas públicas/ano e 218–353 linhas parceiras/ano	Covariada futura, com data de corte; não é denominador da demanda.
Unidades unificadas	unidade; localização	1.941 linhas principais + 1.914 parceiras; 871/872 unidades da Query A vinculadas	Identifica a unidade escolhida na saída final por creche; não substitui a residência da criança.

Achado de qualidade

A malha contém duas geometrias com código 7.28 e uma geometria inválida. Antes de qualquer spatial join, é preciso definir se as duas partes devem ser dissolvidas e reparar a geometria de modo documentado.

Fontes locais auditadas: README_dicionario_dados.md; README.txt da pasta OferecimentosEvagas; SME_Processo_Inscricao_Creche_parametrizações.docx; arquivos CSV, XLSX e shapefile do repositório.

Construção do alvo: contar crianças, não linhas

A Query A tem três camadas de multiplicidade: várias opções por inscrição, mais de uma inscrição da mesma criança no mesmo processo e reaparecimento da criança em anos distintos. A unidade estatística correta para a entrada anual na rede é (ano, aluno_anon). O endereço e o grupamento da primeira ocorrência cronológica resolvem conflitos raros; os conflitos serão mantidos em log de qualidade.

Ano	chaves de inscrição	crianças únicas	excesso se não deduplicar
2021	73.283	57.690	27,03%
2022	64.055	57.820	10,78%
2023	51.331	45.918	11,79%
2024	82.690	71.757	15,24%
2025	71.949	62.899	14,39%
Total	343.308	296.084	15,95%

Definição operacional

$A(m,g,t)$ = número de valores distintos de aluno_anon no ano t, com residência harmonizada no território m e grupamento g, independentemente da situação posterior da opção.

- Não somar filas por creche: a mesma criança aparece em várias opções.
- Não condicionar a Confirmado ou Lista de espera: isso mistura demanda inicial com oferta, prioridade e decisão administrativa.
- Não usar endereço da creche para territorializar a criança: a origem continua sendo a residência; a unidade selecionada aparece apenas no alvo final por creche.

Cobertura

Após harmonizar apenas variantes inequívocas de bairro, 98.73% das crianças-ano entram no painel. Localidades ambíguas não foram imputadas à força.

Primeira inscrição versus reinscrição observada

Ano	primeira observada	reinscrição observada	% reinscrição
2021	57.690	0	0.0%
2022	50.546	7.274	12.6%
2023	44.514	1.404	3.1%
2024	62.441	9.316	13.0%
2025	44.733	18.166	28.9%

Uma reinscrição observada é a aparição da mesma hash aluno_anon em ano posterior. Em 2021, todas as crianças são classificadas como primeira observação por censura à esquerda; portanto, esse rótulo não equivale a “primeira inscrição da vida”. O salto para 18.166 reinscrições em 2025 pode refletir política, fila acumulada, mudança de cobertura ou mecanismo de geração da base — precisa de confirmação operacional.

Modelo modular recomendado

$$A(m,g,t) = A_nova(m,g,t) + A_retorno(m,g,t)$$

- A_nova: universo de crianças elegíveis que nunca havia aparecido antes do corte observado.
- A_retorno: estoque elegível de inscritos não atendidos e/ou candidatos que precisam renovar a manifestação de interesse.
- Para produção, solicitar à SME a distinção nativa entre inscrição inicial, transferência, renovação automática e permanência em fila.

Não usar o questionário como controle de entrada
As respostas socioeconômicas são observadas somente depois que a família já se inscreveu. Elas descrevem quem entrou no cadastro, mas não permitem comparar inscritos e não inscritos; usá-las diretamente na equação de propensão cria seleção por construção.

Universo potencial e a taxa de entrada

O arquivo de nascidos vivos é uma exportação do SINASC por bairro de residência e ano. A fonte administrativa é apropriada para seguir coortes; a SMS informa que o SINASC foi implantado no Rio em 1993 e o TABNET oferece consultas de nascimentos desde 2006 [10].

Grupamento	Proxy de coorte na versão 0.1	Justificativa nos registros
Berçário	Nasc(m,t-1) + Nasc(m,t-2)	Concentra crianças de até dois anos no ano letivo.
Maternal I	Nasc(m,t-3)	Coorte modal compatível com idade observada.
Maternal II	Nasc(m,t-4)	Coorte modal compatível com idade observada.

$$p(m,g,t) = E[A(m,g,t) \mid \text{informação disponível antes da inscrição}] / E(m,g,t)$$

Essa taxa é uma propensão operacional de manifestação de demanda, não uma probabilidade causal. Na base anonimizada, ela pode inclusive exceder limites substantivos porque o README informa que os indicadores não preservam a realidade. Por isso o estimador trabalha a contagem com offset e o PDF evita interpretar p como porcentagem real.

Limitações do denominador atual

- Ano, e não mês: o corte exato de 6 meses a 3 anos e 11 meses não pode ser aplicado ao universo.
- Bairro, e não microárea: não há alocação direta dos nascimentos aos 232 códigos territoriais.
- Mudanças de bairro: novos códigos têm séries históricas nulas e exigem ponte territorial estável.
- Migração entre nascimento e inscrição não é observada.

Próxima base prioritária

Solicitar SINASC com mês de nascimento e residência geocodificada ou já agregada por microárea, sob governança adequada. Esse pedido melhora mais o denominador do que adicionar muitas covariadas de baixa granularidade.

Primeiro modelo estimado

Para cada bairro m , grupamento g e ano t , a versão 0.1 estima:

$$A(m,g,t) \sim \text{Poisson}(\mu(m,g,t))$$
$$\log \mu(m,g,t) = \log E(m,g,t) + \alpha(m) + \gamma(g) + \delta(g) \cdot (t-2021)$$

$\alpha(m)$ são indicadores de bairro, $\gamma(g)$ diferenças médias entre grupamentos e $\delta(g)$ tendências específicas. Os indicadores são estabilizados com ridge ($\alpha = 10^{-4}$) porque há até 166 bairros, três grupamentos e somente três a cinco anos no treino. O PPML é coerente com uma média condicional multiplicativa de contagem e tem fundamentos para painéis com heterogeneidade multiplicativa [4]. Modelar diretamente uma fração seria alternativa quando o denominador real estiver validado [5].


Componente	Incluído agora?	Regra temporal
Coorte elegível	Sim, como offset	Conhecida antes do ano previsto.
Efeito territorial	Sim, bairro	Somente histórico do treino.
Tendência por grupamento	Sim	Extrapolável para ano futuro.
Efeito fixo de ano	Não no forecast	Um dummy de 2025 não existe ao prever 2025; seria inestimável fora da amostra.
Demanda defasada	Benchmark, não regressora	Painel curto gera risco de viés dinâmico [9].
Renda/emprego/CadÚnico	Não	Ausentes em granularidade residencial compatível.
Oferta/capacidade	Não nesta versão	Precisa estar congelada antes da inscrição e ligada ao território de residência.

A literatura econômica torna renda, emprego materno, preço/acesso e estrutura familiar candidatos substantivos [1–3]. Porém, acesso à creche também altera emprego e renda; no experimento do Rio, acesso gratuito afetou resultados laborais maternos [1]. Logo, covariadas contemporâneas podem ter causalidade reversa. Para previsão, usar valores defasados e tratar coeficientes como preditivos, não causais.

Validação fora da amostra: 2025

A avaliação treina o modelo com 2021–2024 e prevê 2025. O ano de 2024 permanece no histórico de estimação, mas não é pontuado como teste OOS porque a expansão de 496 para 844 unidades indica uma quebra de cobertura ou de processo. O desenho preserva a ordem temporal e não utiliza informação de 2025 no ajuste [7].

Teste	Modelo	Obs.	Prev.	WAPE	Viés	MAE	Cob. 95%
2025	PPML-FE	61.902	65.114	24.0%	+5.2%	30.4	86.3%
2025	Persistência	61.902	66.673	16.0%	+7.7%	20.2	—



Leitura: em 2025, o PPML apresenta viés agregado de +5,2%, mas a persistência tem WAPE menor (16,0% contra 24,0%). A cobertura condicional de 95% do PPML é 86,3%; seguindo Gneiting e Raftery [8], cobertura e largura precisam ser avaliadas conjuntamente, e não apenas o ponto médio.

Primeira estimativa para 2026

Grupamento	universo proxy	PPML-FE	persistência	intervalo PPML 95%
Bercario	116.068	29.987	26.081	[28.031; 31.943]
Maternal I	62.526	24.430	21.531	[22.849; 26.010]
Maternal II	64.371	12.384	12.106	[11.574; 13.194]
Total	242.965	66.801	59.718	[64.159; 69.443]

Número de referência
PPML-FE: 66,801. Persistência: 59,718. Diferença: 7,083 crianças na base anonimizada.

O intervalo exibido usa uma distribuição binomial negativa com dispersão estimada nos resíduos ($\alpha \approx 0,0529$), condicionada aos parâmetros e ao universo proxy. Ele não incorpora integralmente erro no SINASC, incerteza de geocodificação, mudança de política ou erro de estimação dos efeitos territoriais. Portanto, é um intervalo mínimo, não uma banda de risco de política pública.

Por que não escolher automaticamente o PPML

- Há apenas um ano OOS comparável depois da exclusão de 2024 das métricas.
- O challenger de persistência venceu o PPML em WAPE no teste de 2025.
- A previsão pontual deve ser reportada como faixa de cenários até que 2024 seja explicado e os dados reais substituam os anonimizados.

Recomendação de auditoria: manter ambos os cenários no painel decisório; promover um modelo a campeão somente após reprocessar dados reais, fixar o corte anual e repetir backtests em mais anos ou origens mensais.

Renda, emprego e vulnerabilidade: o que é utilizável

Fonte	Frequência	Granularidade pública	Veredito para a Frente 1
RAIS / Novo Caged	anual / mensal	microdados não identificados; geografia pública não garante residência em microárea	Não usar como emprego residencial local sem validar campo e série; local do estabelecimento mede outra coisa [14].
CadÚnico aberto	amostra anual; agregados municipais mensais	público chega tipicamente ao município; acesso identificado exige autorização	Insuficiente para microárea pública. Solicitar agregado anual/mensal por residência à gestão municipal [15].
Questionário da inscrição	anual	resposta individual dos inscritos	Não estima a probabilidade de entrar; pode caracterizar composição e classificação.
Data Lake municipal	depende da tabela	BigQuery com permissões por projeto	Infraestrutura confirmada, mas o catálogo público não comprova tabelas específicas de CadÚnico/SME. É necessário acesso e inventário de schema [13].
Habite-se / novas moradias	não presente	não verificada nesta pasta	Candidata, desde que geocodificada e congelada antes do ano previsto.

Pedido mínimo ao Data Lake / SME

- Snapshot anual da inscrição inicial, hash estável da criança, data do evento, grupamento e microárea de residência.
- CadÚnico agregado por microárea e ano-mês: crianças elegíveis, renda per capita, monoparentais, responsável feminino ocupado e benefícios; sem identificadores.
- Estoque anterior: matriculados, não atendidos e renovações por microárea/grupamento, todos no mesmo corte.
- Oferta conhecida antes da inscrição: capacidade pública/parceira, turno, abertura e fechamento.

Critério de admissibilidade

Uma variável só entra no forecast se tiver: residência local compatível; atualização ao menos anual; histórico 2021–2025; data de disponibilidade anterior ao alvo; dicionário estável; e plano explícito para revisões.

Riscos, testes de robustez e próxima iteração

Risco	Evidência atual	Teste / correção
Quebra em 2024	inscritos sobem de 45.918 para 71.757; unidades na Query A de 496 para 844	Separar mudança de cobertura, inclusão de parceiras e mudança de processo; reconstruir universo comparável.
Geografia	bairro informado; 1,1% dos registros múltiplos têm CEP conflitante	Usar residência na data da primeira inscrição; crosswalk CEP→microárea versionado; auditoria de fronteiras.
Denominador	nascimentos anuais, sem mês	Obter mês/microárea; comparar com projeção etária e matrículas passadas.
Painel curto	cinco anos e muitos efeitos	Shrinkage hierárquico; comparar pooling, ridge e intercepto aleatório [6].
Dinâmica	reinscrições crescem fortemente em 2025	Modelar fluxos separadamente; evitar FE dinâmico ingênuo devido ao viés de painel curto [9].
Intervalos	cobertura 95% de 86,3% no OOS de 2025	Bootstrap por território + cenários de corte/política; avaliar interval score [8].

Sequência recomendada

- 1. Explicar e documentar a quebra de 2024; sem isso, nenhum modelo de tendência é auditável.
- 2. Substituir a base anonimizada pelo extrato real agregado, com a mesma lógica de deduplicação.
- 3. Congelar a ponte bairro/microárea e a regra mensal de elegibilidade por grupamento.
- 4. Estimar A_nova e A_retorno separadamente; depois somar distribuições, não só médias.
- 5. Acrescentar covariadas uma a uma, exigindo ganho OOS contra persistência.
- 6. Publicar ficha do modelo: corte, versão das bases, cobertura, métricas e falhas conhecidas.

Saída final por creche

A Frente 1 termina na demanda bruta potencial de cada unidade: o número de crianças distintas que selecionaram a creche em qualquer opção. A mesma criança pode aparecer em várias unidades, mas nunca mais de uma vez dentro da mesma creche e ano. Esta etapa ainda não inclui concorrência, distância, capacidade relativa, substituição entre unidades ou modelo de escolha.

$$D_bruta(i,t) = \text{nº de crianças distintas que selecionam a unidade } i \text{ em qualquer opção}$$
$$D_hat_bruta(i,2025) = A_hat(2025) \times r_hat(i,2025)$$

Campo	Definição	Uso nesta versão	Regra
ano	ano do processo	2021–2024 treino; 2025 OOS	2024 não é pontuado como OOS.
codigo_unidade	creche selecionada	efeito fixo de unidade	Uma linha final por creche continuante.
demanda_observada	crianças distintas por unidade	alvo	Conta qualquer opção; deduplica criança–unidade.
prev_modelo	PPML-FE com tendência	previsão principal	Escalado pelo total previsto de crianças.
prev_persistencia	taxa da unidade em 2024	único benchmark	Aplica a taxa anterior ao total previsto de 2025.

Schema da entrega por unidade

ano_teste | codigo_unidade | nome_unidade | demanda_observada | prev_modelo |
prev_persistencia | erro_abs_modelo | erro_abs_persistencia | vencedor

Limite da entrega

A Frente 2 não foi executada. Concorrência entre creches, distância, conjuntos de alternativas, capacidade e efeitos de abertura/fechamento ficam para uma etapa posterior. Como há múltiplas opções, a soma da demanda bruta entre unidades excede o total de crianças únicas.

Reprodutibilidade e referências

Artefato	Função
f1_est.py	Leitura, deduplicação, painel, PPML, OOS, projeção e exportação.
results/f1_panel.csv	Painel bairro × grupamento × ano construído sem sobrescrever originais.
results/f1_oos_pred.csv	Previsões célula a célula no teste de 2025.
results/f1_oos.csv / .tex	Tabela de métricas.
results/f1_prev_2026.csv	Primeira projeção territorial completa.
results/f1_resumo_2026.csv / .tex	Resumo por grupamento e total.
figures/f1_oos.png	Figura usada nesta nota.
f1c_est.py	Alvo criança-unidade em qualquer opção e OOS por creche em 2025.
results/f1c_oos_pred.csv	Observado, PPML-FE e persistência para cada unidade continuante.
results/f1c_oos.csv / .tex	Métricas por unidade, ponta a ponta e condicionais ao total.
figures/f1c_oos_2025.png	Diagnóstico gráfico da comparação individual por creche.

Referências acadêmicas

- [1] Barros, R. P.; Olinto, P.; Lunde, T.; Carvalho, M. (2013). The impact of access to free childcare on women's labor market outcomes: evidence from a randomized trial in low-income neighborhoods of Rio de Janeiro. World Bank. [fonte](#)
- [2] Heckman, J. J. (1974). Effects of Child-Care Programs on Women's Work Effort. Journal of Political Economy, 82(2). [fonte](#)
- [3] Blau, D. M.; Robins, P. K. (1988). Child-Care Costs and Family Labor Supply. Review of Economics and Statistics, 70(3), 374–381. [fonte](#)
- [4] Wooldridge, J. M. (1999). Distribution-free estimation of some nonlinear panel data models. Journal of Econometrics, 90(1), 77–97. [fonte](#)
- [5] Papke, L. E.; Wooldridge, J. M. (1996). Econometric methods for fractional response variables. Journal of Applied Econometrics, 11(6), 619–632. [fonte](#)
- [6] Rao, J. N. K.; Molina, I. (2015). Small Area Estimation, 2nd ed. Wiley. [fonte](#)
- [7] Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. International Journal of Forecasting, 16(4), 437–450. [fonte](#)
- [8] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. JASA, 102(477), 359–378. [fonte](#)
- [9] Nickell, S. (1981). Biases in Dynamic Models with Fixed Effects. Econometrica, 49(6), 1417–1426. [fonte](#)

Fontes oficiais e documentação

- [10] SMS Rio — SINASC e TABNET municipal. [fonte](#)
- [11] SME Rio — Matrícula 2024: calendário, elegibilidade e processo classificatório. [fonte](#)
- [12] SME Rio — Transparência Creches: fila, matrículas e capacidade com atualização prevista mensal. [fonte](#)
- [13] IplanRio — Data Lake Municipal e acesso via BigQuery. [fonte](#)
- [14] MTE — Microdados RAIS e CAGED. [fonte](#)
- [15] MDS — dados e acesso ao Cadastro Único. [fonte](#)